Emergence and Prediction of New Financial Risk Categories

Workflow Operativo — Piano di Lavoro Dettagliato

A Text-Based Analysis of News and Regulatory Disclosures

Agenda

1. Visione d'Insieme
2. Fase 0 — Setup Infrastrutturale
3. Fase 1 — Costruzione del Corpus
4. Fase 2 — Indicatori Retrospettivi
5. Fase 3 — Stima di t^*
6. Fase 4 — Hazard Models
7. Fase 5 — Early Warning Framework
8. Fase 6 — Validazione di Mercato
9. Fase 7 — Deliverables
10. Rischi e Timeline

Obiettivi del Progetto

RQ1 — Retrospettiva

Come emerge una nuova categoria di rischio finanziario? Quali indicatori osservabili ne precedono il riconoscimento e l'istituzionalizzazione nelle disclosure?

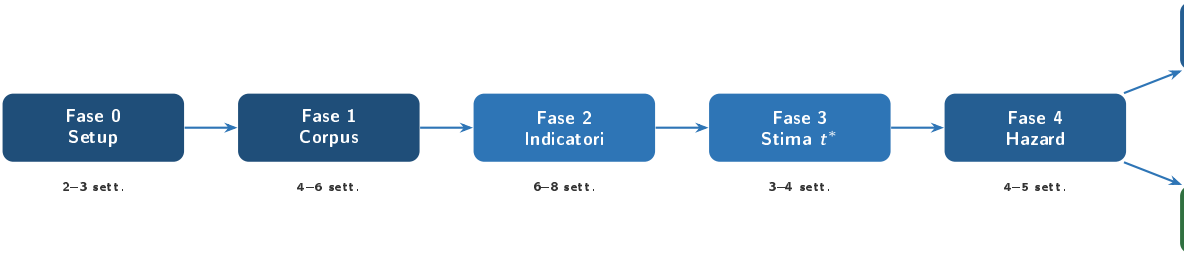
RQ2 — Forward-Looking

Data l'informazione disponibile ad oggi, come si può anticipare l'emergere di un nuovo rischio e stimarne la probabilità per temi candidati (es. AI risk)?

Deliverables principali

- Definizione riproducibile di *risk emergence*
- Toolkit di indicatori testuali quantitativi
- Modello early-warning per rischi emergenti
- Dataset research-ready e paper accademico

Pipeline del Progetto



Durata totale stimata: 8–12 mesi (singolo ricercatore) | 6–8 mesi (team 2–3)

Fase 0 — Setup Infrastrutturale e Governance

▷ 2–3 settimane

0.1 Ambiente di lavoro

- Repository Git modulare: `data/`, `src/`, `notebooks/`, `outputs/`
- Environment riproducibile (conda/poetry)
- Risorse GPU per embedding

0.2 Accesso ai dati

- **News:** Factiva, ProQuest, o scraping (WSJ, NYT, FT, Bloomberg, Reuters)
- **SEC:** EDGAR bulk download (10-K, 8-K)
- **Ausiliari:** CRSP/Compustat, FRED, VIX, EPU

0.3 Perimetro

- Periodo: 2006–2025
- Universo: S&P 500 (con gestione turnover)

0.4 Ground truth

Episodi di validazione noti:

- Cyber risk ∼2013–2015
- Climate/ESG risk ∼2017–2019
- Pandemic risk ∼2020
- AI risk ∼2023–2024

Fase 1 — Ingestion e Costruzione del Corpus

▷ 4–6 settimane

1.1 Filing SEC

- **10-K:** estrarre Item 1A (Risk Factors) con parser HTML/SGML
- **8-K:** testo completo + tipo di Item (1.01, 2.06, 7.01, 8.01)
- Metadati: CIK, ticker, data filing, SIC code

1.2 News

- Titolo, data, testo, sezione, tag
- Deduplicazione cross-fonte
- Provenienza come metadato

1.3 Preprocessing unificato

- Rimozione boilerplate
- Segmentazione in paragrafi
- Entity normalization (fuzzy matching)
- Tokenizzazione & lemmatizzazione
- `document_id` unico → parquet/DB

1.4 Statistiche del corpus

- Documenti per fonte/anno
- Distribuzione lunghezze
- Copertura imprese, lacune
- → Appendice C del paper

Fase 2A — Indicatori News-Based

▷ 6–8 settimane (totale Fase 2)

2A.1 Coverage Intensity

Serie temporale mensile di menzioni normalizzate per volume totale. Smoothing via media mobile o filtro HP.

2A.2 Burst Detection

Algoritmo di Kleinberg / CUSUM sulle frequenze → intervalli di attenzione anomala con inizio, fine, intensità.

2A.3 Novelty & Semantic Drift

Embedding (FinBERT, MiniLM) → distanza coseno inter-periodo (novelty) e dispersione

2A.4 Entity Co-Mention Network

Grafo bipartito tema × entità per finestra temporale. Metriche: nodi, densità, centralità.

2A.5 Contextual Diversification

Classificazione per settore e topic (LDA/BERTopic). Indice di diversificazione: entropia di Shannon.

Insight chiave

Un rischio emergente mostra: burst → novelty alta → rete in espansione → diversificazione contestuale → consolidamento semantico

Fase 2B — Indicatori Disclosure-Based

2B.1 Diffusion Curve $D_r(t)$

$$D_r(t) = \frac{\text{Imprese che menzionano } r \text{ al tempo } t}{\text{Totale imprese al tempo } t}$$

Curva chiave per la definizione di t^*.

2B.2 Disclosure Intensity

- N. paragrafi dedicati al tema
- Quota della sezione Risk Factors
- Posizione nella sezione (ordine $\approx$ importanza percepita)

2B.3 8-K Leading Indicator

Serie mensile di 8-K che menzionano il tema, normalizzata. Stima del lead rispetto alla prima apparizione nel 10-K della stessa impresa.

2B.4 Co-Occurrence

Matrice tema $\times$ risk-category per anno.

Pattern atteso: associazione iniziale a categorie esistenti $\rightarrow$ progressiva differenziazione (sottosezione dedicata).

Fase 3 — Stima del Tempo di Emergence t^*

▷ 3–4 settimane

3.1 Change-Point Detection

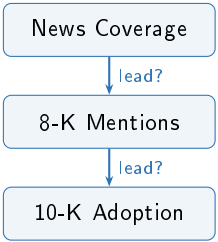
- **PELT** (Pruned Exact Linear Time) — change-point multipli
- **Bayesian CP** (`ruptures` / `bcp`)
- **CUSUM** — alternativa non-parametrica

t^* = primo CP significativo: $D_r(t)$ transita da regime basso a regime alto.

3.2 Validazione

- Confronto t^* stimato vs. eventi esterni (Fase 0.4)
- Distanza media in mesi
- Robustezza: soglie, metodi, definizioni di $D_r(t)$

3.3 Lead-Lag Analysis



- Granger causality test
- Cross-correlation functions
- Lead tipico in mesi/trimestri

Fase 4 — Modelli di Event-History

▷ 4–5 settimane

4.1 Definizione dell'evento

Prima menzione del risk r in Item 1A del 10-K dell'impresa i.

Censura a destra se non adotta entro la fine del campione.

4.2 Cox Proportional Hazard

$$h_i(t) = h_0(t)\,\exp\!\left(\mathrm{x}_i(t)'\beta\right)$$

Covariate (time-varying):

- Coverage intensity, novelty, burst
- Esposizione settoriale (SIC)
- Dimensione (log total assets)
- Peer effects (diffusione nel settore)
- Macro: VIX, EPU

4.3 Competing Risks

Se più temi emergono contemporaneamente: modello Fine-Gray per tener conto dell'interazione tra adozioni.

4.4 Diagnostica

- Schoenfeld residuals (proporzionalità)
- Forme funzionali alternative
- Influenza di osservazioni anomale

Alternative parametriche

Weibull, log-logistic — utili se l'hazard ha un andamento monotono o non-monotono noto a priori.

Fase 5 — Framework Forward-Looking

▷ 5–6 settimane

5.1 Feature Engineering

- Per ogni tema e data τ: tutti gli indicatori di Fase 2 con info $\leq \tau$
- **Nessun look-ahead**
- Panel: (tema, τ) $\rightarrow$ vettore di features

5.2 Target binario

$$Y_{r,\tau,h} = 1\big[D_r(\tau + h) > \bar{D} \text{ o CP raggiunto}\big]$$

Orizzonti: $h \in \{3, 6, 12\}$ mesi.

5.3 Modello

- Logit/probit (interpretabilità)
- Random forest, GBM (flessibilità)
- Rolling-window: training $\leq \tau - h$

5.4 Valutazione

- Reliability diagram (calibrazione)
- AUC, precision-recall, F1
- Sensitività: definizioni, finestra
- Benchmark naive: estrapolazione lineare

5.5 Applicazione: AI Risk

Sotto-temi monitorati:

1. Model risk
2. AI regulation
3. Data governance
4. AI security
5. IP / copyright
6. Workforce displacement

Fase 6 — Validazione di Mercato

▷ 3–4 settimane

6.1 Event Study attorno a t^*

- Abnormal returns (market model) per le imprese nel settore più esposto
- Finestra attorno a t^*
- Test su aumento della volatilità settoriale (GARCH / realized vol.)

6.2 Cross-Section dei Rendimenti

- Early adopters vs. late adopters
- Premia di rischio differenziali
- Controlli: size, B/M, momentum

Nota

Fase opzionale ma fortemente raccomandata: rafforza la rilevanza economica e la credibilità dei risultati.

Fase 7 — Redazione e Deliverables

▷ **4–6 settimane (in parallelo)**

7.1 Dataset

- Panel impresa-anno (disclosure)
- Serie tema-mese (news)
- Stime di t^*
- Output forward-looking
- Codebook completo

7.2 Paper

1. Introduzione
2. Literature review
3. Dati e corpus
4. Definizione emergence
5. Risultati retrospettivi
6. Framework forward
7. Applicazione AI risk
8. Conclusioni

Target: JFE, RFS, JFQA, J. Fin. Econometrics

7.3 Toolkit Python

Pacchetto modulare:

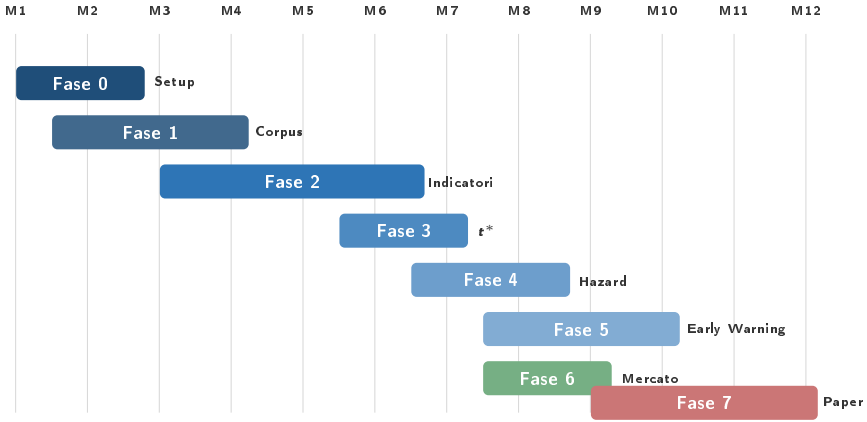
- Definire tema candidato
- Calcolo automatico indicatori
- Stima probabilità emergence

Impatto accademico e pratico.

Rischi del Progetto e Mitigazioni

Rischio	Descrizione	Mitigazione
Accesso dati news	Full-text costoso / vincolato da licenze	Fonti open (GDELT, Reuters wire); accesso accademico
Parsing SEC	HTML eterogeneo e malformato su EDGAR	Parser consolidati; ispezione manuale campione
Ground truth scarsa	Solo 5–8 episodi ben documentati	Rischi più granulari; bootstrap / leave-one-out
Definizione emergence	Soglie e metodi influenzano t^*	Sensitività sistematica; risultati multi-specifica

Timeline Indicativa



Grazie

Domande e discussione

Emergence and Prediction of New Financial Risk Categories
Workflow Operativo